UNIVERSITÀ DEGLI STUDI DI PALERMO

dipartimento di ingegneria unipa

*Python*

# Esercitazione Clustering

A.A. 2025/2026

Prof. Salvatore Contino

salvatore.contino01@unipa.it

# Informazioni generali

Prof. Salvatore Contino

Ph.D. in Ingegneria Informatica
RTD-a IBIO-01/A

Sezione di informatica edificio 6, 3° piano,
Laboratorio d'Interazione Uomo-Macchina

E-mail: salvatore.contino01@unipa.it

# AI per la salute

Le attività del laboratorio si focalizzano:

- **Medicina di Precisione**
  - Modelli multimodali per la diagnosi precoce
  - Modelli multimodali per la risposta farmaceutica ed il follow-up
  - Digital Pathology per il supporto al reparto di anatomia patologica
  - Clustering di popolazione per individuare malattie metaboliche del fegato

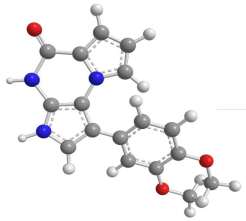

- **Ricerca farmaceutica**
  - Drug Discovery
  - Drug Repurposing
  - Hierarchical Graph Explainer

- **Sviluppo di algoritmi e strutture dati innovative**
  - Federated Learning e algoritmi di gestione di unbalanced data
  - Sviluppo di algoritmi di segmentazione condizionati dal testo
  - Studio dei meccanismi di Reasoning
  - Ontologie e OntoRAG
  - LLMs per la telemedicina (foglio dimissioni e gestione P.S.)
  - Nuovi modelli per classificazione e segmentazione

**Link download**

https://github.com/CHILab1/Esercitazioni-Big-Data.git

**Dataset download**

| Categoria | Variabile | Descrizione |
|---|---|---|
| *Demografica* | age | Età del paziente (anni) |
| *Demografica* | sex | Sesso (M/F) |
| *Demografica* | race | Etnia |
| *Demografica* | income | Livello di reddito |
| *Demografica* | edu | Anni di istruzione |
| *Clinica* | dzgroup | Gruppo diagnostico principale |
| *Clinica* | dzclass | Classe diagnostica aggregata |
| *Clinica* | num.co | Numero di comorbidità |
| *Clinica* | diabetes | Presenza diabete |
| *Clinica* | dementia | Presenza demenza |
| *Clinica* | ca | Presenza cancro |
| *Parametri vitali* | scoma | Livello di coma |
| *Parametri vitali* | meanbp | Pressione arteriosa media |
| *Parametri vitali* | hrt | Frequenza cardiaca |
| *Parametri vitali* | resp | Frequenza respiratoria |
| *Parametri vitali* | temp | Temperatura corporea |
| *Parametri vitali* | wblc | Globuli bianchi |
| *Laboratorio* | alb | Albumina |
| *Laboratorio* | bili | Bilirubina |
| *Laboratorio* | crea | Creatinina |
| *Laboratorio* | sod | Sodio |
| *Laboratorio* | ph | pH sangue |
| *Laboratorio* | glucose | Glucosio |
| *Laboratorio* | bun | Azoto ureico |
| *Laboratorio* | urine | Produzione di urina |
| *Laboratorio* | pafi | Rapporto ossigenazione |
| *Score* | aps | Acute Physiology Score |
| *Score* | sps | Support Prognostic Score |
| *Funzionalità* | adlp | Attività quotidiane prima del ricovero |
| *Funzionalità* | adls | Attività quotidiane al ricovero |
| *Funzionalità* | adlsc | Versione categorizzata |
| *Costi* | charges | Costi ospedalieri |
| *Costi* | totcst | Costo totale |
| *Costi* | totmcst | Costo medico totale |
| *Costi* | avtisst | Costo medio giornaliero |
| *Outcome* | death | Morte (0/1) |

UNIVERSITÀ DEGLI STUDI DI PALERMO

# Esercizi da svolgere

1. Si consideri il dataset clinico SUPPORT2, contenente informazioni demografiche, fisiologiche e di laboratorio relative a pazienti ospedalizzati. Dopo aver caricato i dati, rimuovere le variabili di outcome e prognosi per evitare fenomeni di data leakage e selezionare una variabile target (ad esempio *dzgroup*).

2. Suddividere il dataset in training set (95%) e test set (5%) utilizzando un campionamento stratificato rispetto alla variabile target (*«death»*), in modo da preservare la distribuzione delle classi.

3. Gestire i dati mancanti applicando imputazione con mediana per le variabili numeriche e con un valore costante (ad esempio "Unknown") per quelle categoriche; successivamente codificare le variabili categoriche tramite Ordinal Encoding.

4. Applicare lo scaling delle feature numeriche tramite z-scoring, quindi calcolare e analizzare la matrice di correlazione, individuando eventuali coppie di variabili altamente correlate e discutendo la presenza di multicollinearità.

5. Gestire la multicollinearità mediante rimozione di feature ridondanti o tramite una trasformazione lineare (ad esempio PCA), e infine applicare un metodo di selezione delle feature per identificare le variabili più rilevanti, commentando criticamente i risultati ottenuti.

# Esercizi da svolgere

5. Implementare un clustering dei punti del data set processato nelle fasi precedenti, utilizzando l'algoritmo DBSCAN con una griglia di ricerca degli iper-parametri:
   MinPts = 5, 10, 20
   Eps = 0.5, 1.5, 2.0

   Stampare l'accuracy del modello di clustering sul training set e sul test set. Valuta la purezza del clustering.

6. Implementare un clustering dei punti del dataset processato nelle fasi precedenti, utilizzando un secondo algoritmo di clustering. La selezione dell'algoritmo deve essere coerente con la natura del dato. Valuta la purezza del clustering.

7. Esegui la comparazione delle performance utilizzando l'etichetta «*death*» con criteri di valutazione esterni.